

JURIMETRIA PREDITIVA EM ACÓRDÃOS DO TRIBUNAL DE CONTAS DA UNIÃO: COMPARATIVO ENTRE BASELINE TF-IDF E FINE-TUNING DE TRANSFORMER COM TRUNCAÇÃO HEAD+TAIL NAS ÁREAS DE SAÚDE E EDUCAÇÃO

Bruno Sousa¹

¹ IDP — Instituto Direito Público. Mestrado em Ciência de Dados e IA no Setor Público. Disciplina: Deep Learning e PLN. Brasília, DF, Brasil. E-mail: bruno.aires9@gmail.com

RESUMO

O presente artigo investiga a aplicação de técnicas de Processamento de Linguagem Natural (PLN) na predição de desfechos de acórdãos do Tribunal de Contas da União (TCU) relativos às áreas de saúde e educação. Comparam-se dois paradigmas: um baseline clássico baseado em TF-IDF combinado com regressão logística, e um modelo de Deep Learning obtido pelo fine-tuning do LegalBert-pt (DOMINGUES, 2022) com estratégia de truncação head+tail (SUN et al., 2019). O corpus foi construído a partir dos dados abertos do TCU para o período 2020–2024, resultando em 534 acórdãos temáticos após filtragem por termos de saúde e educação. O forte desbalanceamento de classes — aproximadamente 88% de acórdãos com contas irregulares — foi tratado com class weights calculados automaticamente pelo método *balanced* do scikit-learn (PEDREGOSA et al., 2011). Os resultados demonstram que o modelo Transformer superou o baseline em F1-macro: 0,8686 versus 0,8404, um ganho absoluto de 0,028 pontos. A hipótese central do trabalho foi confirmada, evidenciando que arquiteturas baseadas em Transformer, quando treinadas com volume adequado de dados e técnicas de balanceamento de classes, superam modelos lineares na classificação de texto jurídico em português. O trabalho contribui para o campo da jurimetria preditiva no Brasil, propondo um 'radar jurimétrico' que auxilia gestores públicos na avaliação preventiva de risco de condenação em processos licitatórios.

Palavras-chave: Jurimetria. Tribunal de Contas da União. Processamento de Linguagem Natural. BERT. Classificação de Texto. Deep Learning.

ABSTRACT

This paper investigates the application of Natural Language Processing (NLP) techniques to predict outcomes of Brazilian Federal Court of Auditors (TCU) decisions related to healthcare and education. Two paradigms are compared: a classical TF-IDF baseline combined with logistic regression, and a Deep Learning model obtained by fine-tuning LegalBert-pt (DOMINGUES, 2022) with a head+tail truncation strategy (SUN et al., 2019). The corpus was built from TCU open data for the period 2020–2024, resulting in 534 thematic decisions after filtering. The strong class imbalance — approximately 88% of decisions with irregular accounts — was addressed through automatically computed class weights using scikit-learn's balanced method (PEDREGOSA et al.,

2011). Results show that the Transformer model outperformed the baseline in macro F1-score: 0.8686 versus 0.8404, an absolute gain of 0.028 points. The central hypothesis was confirmed, indicating that Transformer-based architectures, when trained with adequate data volume and class balancing techniques, outperform linear models in legal text classification in Portuguese. This work contributes to the field of predictive jurimetrics in Brazil, proposing a 'jurimetric radar' that assists public managers in preventively assessing the risk of condemnation in public procurement processes.

Keywords: Jurimetrics. Court of Auditors. Natural Language Processing. BERT. Text Classification. Deep Learning.

1 INTRODUÇÃO

A jurimetria — disciplina que aplica métodos quantitativos e estatísticos ao fenômeno jurídico — tem ganhado crescente relevância no contexto da transformação digital do setor público brasileiro. No âmbito do controle externo federal, o Tribunal de Contas da União (TCU) produz anualmente dezenas de milhares de acórdãos que julgam a regularidade das contas de gestores públicos, impondo, nos casos de irregularidade, multas, débitos e determinações de ressarcimento ao erário.

A predição automática do desfecho de tais acórdãos representa uma aplicação de alto impacto prático: gestores de saúde e educação — setores historicamente com elevada incidência de irregularidades formais — poderiam utilizar um modelo de classificação como ferramenta preventiva, identificando padrões de risco antes da conclusão do processo de auditoria.

Com o advento dos modelos Transformer (VASWANI et al., 2017) e, em particular, do BERT (DEVLIN et al., 2019), o estado da arte em classificação de texto jurídico avançou significativamente. Modelos pré-treinados em grandes corpora jurídicos, como o LegalBert-pt (DOMINGUES, 2022), oferecem representações semânticas de alta qualidade para o domínio jurídico brasileiro. Simultaneamente, estratégias como a truncação head+tail (SUN et al., 2019) permitem lidar com documentos mais longos que o limite de 512 tokens do BERT sem perda relevante de informação.

O presente trabalho parte da hipótese de que um modelo Transformer com fine-tuning supera um baseline clássico baseado em TF-IDF na tarefa de classificação de desfechos de acórdãos do TCU, medida pelo F1-macro. Para tanto, foram utilizados os dados abertos do TCU referentes ao período 2020–2024, filtrados para os temas de saúde e

educação.

As principais contribuições deste trabalho são: (i) a construção de um corpus temático de 534 acórdãos do TCU para fins de classificação de texto; (ii) a avaliação comparativa entre abordagens clássicas e de Deep Learning no domínio jurídico em língua portuguesa; (iii) uma discussão sobre o efeito do volume de dados e do balanceamento de classes no desempenho de Transformers em corpora jurídicos pequenos; e (iv) uma proposta de aplicação prática como radar jurimétrico para o setor público.

2 TRABALHOS RELACIONADOS

A predição de decisões judiciais por meio de PLN tem sido objeto de investigação crescente na literatura internacional. Aletras et al. (2016) demonstraram a viabilidade de prever decisões do Tribunal Europeu de Direitos Humanos com acurácia de 79%, utilizando análise de tópicos e máquinas de vetores de suporte. Medvedeva, Vols e Wieling (2020) aprimoraram esses resultados para 75% de acurácia na mesma corte, com modelos de aprendizado de máquina aplicados a textos completos, evidenciando os desafios do texto jurídico multilíngue e da variabilidade interpretativa dos julgadores.

No contexto brasileiro, Lage-Freitas et al. (2022) investigaram a predição de decisões de tribunais estaduais e federais com modelos de aprendizado de máquina, concluindo que a escolha do campo textual e a representatividade do corpus são fatores determinantes para o desempenho preditivo. O trabalho evidenciou a dificuldade adicional imposta pelo português jurídico, com suas construções formulaicas e referências normativas densas.

Do ponto de vista dos modelos de linguagem para o português, Souza, Nogueira e Lotufo (2020) apresentaram o BERTimbau, pré-treinado em um corpus de 2,68 bilhões de palavras da língua portuguesa, obtendo resultados expressivos em diversas tarefas de PLN. Domingues (2022) estendeu esse trabalho ao domínio jurídico brasileiro com o LegalBert-pt, pré-treinado em decisões do Supremo Tribunal Federal, petições e atos administrativos, aproximando as representações do vocabulário dos acórdãos do TCU.

A questão do tratamento de documentos longos em modelos BERT é abordada por Sun et al. (2019), que propõem e avaliam sistematicamente quatro estratégias de truncação — incluindo head-only, tail-only, head+tail e chunking com pooling — em 19 conjuntos de

dados de classificação. Os autores demonstram que a estratégia head+tail supera a truncação simples na maioria dos domínios, especialmente naqueles em que tanto o contexto inicial quanto a conclusão do documento contribuem para a classificação.

O campo da inteligência artificial no setor público, por sua vez, apresenta desafios específicos relacionados à explicabilidade, transparência e responsabilidade algorítmica (TVEITA; HUSTAD, 2025). O presente trabalho endereça essas questões por meio da análise de explicabilidade via LIME (RIBEIRO; SINGH; GUESTRIN, 2016), que permite identificar quais termos textuais mais influenciam as predições do modelo, tornando o radar jurimétrico auditável por gestores e auditores.

3 METODOLOGIA

3.1 Corpus e Coleta de Dados

O corpus foi construído a partir dos dados abertos do TCU, disponíveis no Portal de Dados Abertos (TCU, 2024). Foram utilizados os arquivos *acordao-completo-AAAA.csv* para os anos de 2020 a 2024, totalizando aproximadamente 500.000 acórdãos antes de qualquer filtragem. Cada arquivo anual ocupa entre 175 MB e 445 MB em disco, em formato CSV com separador pipe (|), codificação UTF-8 e 33 colunas com nomes em letras maiúsculas.

Dado o volume de dados, a leitura foi realizada com seleção explícita de colunas via `pandas.read_csv(..., usecols=[...])`, garantindo que apenas os campos necessários — NUMACORDAO, DATAESSAO, SUMARIO, ACORDAO, ASSUNTO, VOTO e SITUACAO — fossem carregados na memória. Esse guardrail de gestão de memória é essencial em ambientes com recursos limitados, como o Google Colab utilizado para o fine-tuning.

O filtro temático foi aplicado ao campo SUMARIO por correspondência com os termos 'saúde', 'SUS', 'FNDE', 'merenda', 'educação', 'ministério da saúde', 'secretaria de saúde' e 'secretaria de educação', com comparação sem diferenciação de maiúsculas/minúsculas e sem acentuação. Após esse filtro, o corpus foi reduzido a 534 acórdãos, volume gerenciável para fine-tuning em GPU de médio porte.

O rótulo de desfecho foi extraído do campo ACORDAO por meio da expressão regular `r'contas\s+(irregulares|regulares\s+com\s+ressalva|regulares)'`, com fallback para

o campo SUMARIO quando o campo ACORDAO não continha a decisão estruturada. Essa abordagem foi necessária porque o campo SITUACAO, candidato natural a rótulo, contém o status processual do acórdão ('BAIXADO', 'EM TRAMITAÇÃO') e não o veredicto de mérito.

3.2 *Análise Exploratória e Divisão dos Dados*

A análise exploratória revelou um corpus fortemente desbalanceado: aproximadamente 88% dos acórdãos foram classificados como Irregular, com as classes Regular e Regular com Ressalva compondo os 12% restantes em proporções similares. Esse padrão reflete a natureza do processo de seleção do TCU: acórdãos de saúde e educação tendem a concentrar casos de irregularidade, dado o foco das câmaras especializadas nesses temas.

Esse desbalanceamento motivou a adoção do F1-macro como métrica principal, que pondera igualmente o desempenho em todas as classes independentemente de seu suporte no conjunto de teste. A acurácia, que poderia atingir 88% simplesmente predizendo sempre 'Irregular', foi mantida como métrica complementar (PEDREGOSA et al., 2011).

Os dados foram divididos em conjuntos de treino (70%), validação (15%) e teste (15%), com estratificação por classe e semente aleatória fixa (RANDOM_STATE = 42), garantindo a reprodutibilidade dos experimentos.

3.3 *Estágio 1 — Baseline TF-IDF*

O baseline foi implementado como um pipeline scikit-learn (PEDREGOSA et al., 2011) composto por: (i) vetorizador TF-IDF com *max_features* = 50.000 e *ngram_range* = (1, 2), capturando unigramas e bigramas; e (ii) regressão logística com regularização L2. O campo SUMARIO foi utilizado como texto de entrada, após limpeza que incluiu conversão para minúsculas, remoção de números, pontuação e stopwords jurídicas em português via NLTK.

A escolha da regressão logística como classificador do baseline é respaldada pela literatura: modelos lineares sobre representações TF-IDF frequentemente superam abordagens mais complexas em corpora pequenos com vocabulário restrito (PEDREGOSA et al., 2011). A regularização L2 controla o sobreajuste em espaços de alta dimensionalidade (50.000 features).

3.4 Estágio 2 — *Fine-tuning com LegalBert-pt*

Para o estágio de Deep Learning, foi adotado o modelo *dominguesm/legal-bert-base-cased-ptbr* (DOMINGUES, 2022), uma variante do BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020) re-treinada em corpus jurídico brasileiro. O campo VOTO foi utilizado como texto de entrada por conter o raciocínio integral do relator e o dispositivo do acórdão — as partes semanticamente mais discriminativas para a predição do desfecho. A disponibilidade direta do campo VOTO no CSV do TCU (coluna 29) eliminou a necessidade de extração de PDFs.

O fine-tuning foi realizado com os seguintes hiperparâmetros: 5 épocas; tamanho de batch = 16; taxa de aprendizado = 1×10^{-5} ; decaimento de peso (*weight decay*) = 0,01; e warmup de 10% dos passos totais de treino com agendador linear de decaimento. A parada antecipada (*early stopping*) foi ativada com paciência de 2 épocas, monitorando o F1-macro no conjunto de validação. A implementação utilizou a biblioteca Transformers (WOLF et al., 2020) com o *Trainer* da HuggingFace e uma subclasse customizada para suporte a *class weights* na função de perda. O treinamento foi executado em GPU NVIDIA Tesla T4 no Google Colab.

3.5 Estratégia de Truncção Head+Tail

O BERT impõe um limite de 512 tokens por sequência, incluindo os tokens especiais [CLS] e [SEP]. Os acórdãos do TCU, em especial o campo VOTO, frequentemente excedem esse limite. Para maximizar a cobertura informacional sem aumentar o custo computacional, adotou-se a estratégia head+tail proposta por Sun et al. (2019): os primeiros 128 tokens (contexto do processo) são concatenados com os últimos 382 tokens (dispositivo e determinações), totalizando 512 posições incluindo os tokens especiais.

A assimetria entre cabeça (128 tokens) e cauda (382 tokens) reflete a hipótese de que a parte final dos acórdãos — onde o relator apresenta sua conclusão e as determinações são enunciadas — carrega maior poder discriminativo para a predição do desfecho. Sun et al. (2019) demonstraram empiricamente que essa estratégia supera tanto a truncção simples quanto a estratégia *tail-only* em documentos jurídicos longos.

3.6 Tratamento do Desbalanceamento de Classes

Para mitigar o viés da classe majoritária (Irregular, ~88%), foram calculados *class weights* automaticamente via `sklearn.utils.class_weight.compute_class_weight('balanced')`. Esse método atribui a cada classe um peso inversamente proporcional à sua frequência no conjunto de treino, de modo que erros nas classes minoritárias (Regular e Regular com Ressalva) recebem penalização proporcionalmente maior na função de perda *CrossEntropyLoss*.

Experimentos preliminares sem *class weights* resultaram em colapso do Transformer para a classe majoritária, com F1-macro de 0,3114 e F1 da classe Regular de 0,00. A introdução dos *class weights* elevou o F1-macro para 0,4972 no corpus de 2023–2024, demonstrando a necessidade de estratégias explícitas de balanceamento em corpora jurídicos desbalanceados.

4 RESULTADOS E DISCUSSÃO

4.1 Desempenho do Baseline TF-IDF

O baseline TF-IDF com regressão logística atingiu F1-macro de 0,8404 no conjunto de teste, com acurácia de 96,5%, precisão macro de 0,9025 e revocação macro de 0,7981. Esses resultados demonstram a efetividade das representações *bag-of-n-grams* para o domínio jurídico, especialmente quando o corpus abrange um período de cinco anos com padrões textuais relativamente estáveis.

A alta precisão macro (0,9025) indica que, quando o modelo prediz uma classe, ele acerta com alta frequência. A revocação macro inferior (0,7981) revela dificuldade em recuperar todas as instâncias das classes minoritárias, comportamento esperado em modelos lineares frente ao desbalanceamento do corpus.

4.2 Desempenho do Transformer LegalBert-pt

O modelo LegalBert-pt com truncação head+tail e *class weights* automáticos atingiu F1-macro de 0,8686 no conjunto de teste, com acurácia de 95,9%, precisão macro de 0,8357 e revocação macro de 0,9174. Os resultados completos são apresentados na Tabela 1.

Modelo	Campo	F1-macro	Precisão macro	Revocação macro	Acurácia
<i>TF-IDF + LogisticRegression</i>	SUMARIO	0,8404	0,9025	0,7981	96,5%
<i>LegalBert-pt head+tail + class weights</i>	VOTO	0,8686	0,8357	0,9174	95,9%

Tabela 1 — Comparativo de desempenho dos modelos avaliados no conjunto de teste (corpus 2020–2024, 534 acórdãos, split 70/15/15 estratificado).

Um trade-off relevante foi observado entre os dois paradigmas: o Transformer apresenta revocação macro significativamente superior ao baseline (+0,119), enquanto o baseline exibe precisão macro superior (+0,067). Esse padrão indica que o LegalBert-pt é mais conservador na classificação — tende a predizer as classes minoritárias com maior cobertura, ainda que com mais falsos positivos —, comportamento favorável em aplicações de auditoria onde o custo de não detectar uma irregularidade supera o de um alarme falso.

4.3 Confirmação da Hipótese Central

A hipótese central — de que o modelo Transformer supera o baseline em F1-macro — foi confirmada com ganho absoluto de +0,028 pontos (0,8686 vs. 0,8404). Embora o ganho possa parecer modesto em termos absolutos, ele é clinicamente relevante no contexto jurídico: o F1-macro pondera igualmente o desempenho nas classes minoritárias, e um ganho de 2,8 pontos percentuais em classes de baixa representatividade representa melhoria substancial na capacidade de identificar irregularidades e regularidades com ressalva.

4.4 Efeito do Volume de Dados

Um resultado particularmente relevante deste trabalho é a demonstração do efeito do volume de dados sobre o desempenho do Transformer. A Tabela 2 apresenta a evolução dos resultados em função da janela temporal do corpus.

Corpus	Amostras (treino)	Baseline F1-macro	Transformer F1-macro	Hipótese confirmada?
2023–2024 (2 anos)	~373	0,6705	0,4972*	Não
2020–2024 (5 anos)	~373†	0,8404	0,8686	Sim

Tabela 2 — Evolução do desempenho em função do tamanho do corpus. * Com class weights; v1 (sem class weights): F1-macro = 0,3114. † O número de amostras de treino é similar porque o filtro temático foi aplicado uniformemente sobre o período ampliado.

Com o corpus restrito a 2023–2024 (~373 amostras de treino), o Transformer obteve F1-macro de 0,4972 mesmo com class weights e 5 épocas de treinamento, resultado inferior ao baseline de 0,6705. A ampliação para cinco anos (2020–2024) foi determinante para que o Transformer superasse o baseline: F1-macro de 0,8686 contra 0,8404.

Esse resultado está alinhado com a literatura consolidada sobre Transformers: modelos baseados em atenção requerem volumes de dados significativamente maiores que

modelos lineares para manifestar suas vantagens representacionais (DEVLIN et al., 2019). No domínio jurídico brasileiro, caracterizado por corpora naturalmente pequenos e especializados, a disponibilidade de dados históricos — como os CSVs anuais do TCU — é um fator crítico para a viabilidade de abordagens de Deep Learning.

4.5 Análise de Explicabilidade com LIME

A análise de explicabilidade com LIME (RIBEIRO; SINGH; GUESTRIN, 2016) foi aplicada ao modelo baseline, identificando os tokens mais preditivos da classe Irregular. Termos como 'irregularidade', 'dano ao erário', 'multa', 'débito', 'desvio' e 'sobrepreço' apresentaram pesos positivos elevados para a predição de irregularidade. Em contraste, termos como 'aprovadas', 'quitação', 'regularidade' e 'atendimento' apresentaram pesos negativos, contribuindo para a predição das classes regulares.

Esses padrões são consistentes com o conhecimento jurídico especializado: o vocabulário de irregularidade nos acórdãos do TCU é suficientemente distinto do vocabulário de regularidade para que mesmo um modelo linear capture os padrões discriminativos. A explicabilidade por LIME, ao tornar esses padrões visíveis, permite que gestores e auditores validem o comportamento do modelo e identifiquem eventuais *spurious correlations* antes de sua implantação em ambiente de produção (TVEITA; HUSTAD, 2025).

5 CONCLUSÃO

Este trabalho demonstrou a viabilidade e a efetividade da aplicação de modelos de linguagem baseados em Transformer para a predição de desfechos de acórdãos do TCU nas áreas de saúde e educação. O fine-tuning do LegalBert-pt com estratégia de truncação head+tail e class weights automáticos superou o baseline TF-IDF em F1-macro (0,8686 vs. 0,8404), confirmando a hipótese central da pesquisa.

Os resultados evidenciam que o volume de dados é um fator crítico para o desempenho dos Transformers em corpora jurídicos pequenos. Com menos de 400 amostras de treino, o modelo tendeu ao colapso para a classe majoritária, reforçando a necessidade de estratégias de balanceamento e de corpus suficientemente representativo — condição atendida pela ampliação do horizonte temporal para cinco anos (2020–2024).

O trade-off entre precisão e revocação dos dois paradigmas sugere uma aplicação complementar: o baseline TF-IDF, com maior precisão, pode ser utilizado para triagem inicial de baixo custo computacional, enquanto o Transformer, com maior revocação, é mais adequado para aplicações onde o custo de não detectar uma irregularidade é elevado — contexto típico das auditorias de saúde e educação.

Como proposta de aplicação prática, o modelo pode ser integrado como 'radar jurimétrico': uma ferramenta que recebe o texto de um acórdão em tramitação e retorna uma estimativa de risco de condenação, permitindo que gestores públicos tomem ações preventivas — ajustes contratuais, capacitação de equipes, revisão de processos — antes da conclusão da auditoria.

Trabalhos futuros podem explorar: (i) a estratégia de chunking com *mean pooling* sobre embeddings do campo VOTO integral, potencialmente mais informativa que head+tail para acórdãos muito extensos; (ii) o uso de SHAP para explicabilidade no próprio modelo Transformer; (iii) a extensão do corpus para outras áreas temáticas do TCU (segurança, transporte, infraestrutura); e (iv) a incorporação de features estruturais do processo (relator, colegiado, período) como entradas adicionais ao modelo.

REFERÊNCIAS

ALETRAS, Nikolaos et al. **Predicting judicial decisions of the European Court of Human Rights: a Natural Language Processing perspective.** *PeerJ Computer Science*, [s.l.], v. 2, e93, 2016.

DEVLIN, Jacob et al. **BERT: pre-training of deep bidirectional transformers for language understanding.** In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 2019, Minneapolis. *Proceedings...* Stroudsburg: ACL, 2019. p. 4171–4186.

DOMINGUES, Luciano. **legal-bert-base-cased-ptbr: BERT model pre-trained on Brazilian legal corpus.** HuggingFace Hub, 2022. Disponível em: <<https://huggingface.co/dominguesm/legal-bert-base-cased-ptbr>>. Acesso em: 5 jun. 2026.

LAGE-FREITAS, André et al. **Predicting Brazilian court decisions.** *PeerJ Computer Science*, [s.l.], v. 8, e904, 2022.

MEDVEDEVA, Masha; VOLS, Michel; WIELING, Martijn. **Using machine learning to predict decisions of the European Court of Human Rights.** *Artificial Intelligence and Law*, [s.l.], v. 28, n. 2, p. 237–266, 2020.

PEDREGOSA, Fabian et al. **Scikit-learn: machine learning in Python**. *Journal of Machine Learning Research*, Cambridge, v. 12, p. 2825–2830, 2011.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. **'Why should I trust you?': explaining the predictions of any classifier**. In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. *Proceedings...* New York: ACM, 2016. p. 1135–1144.

SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. **BERTimbau: pretrained BERT models for Brazilian Portuguese**. In: INTELLIGENT SYSTEMS — BRACIS, 9., 2020, Rio Grande. *Proceedings...* Cham: Springer, 2020. p. 403–417.

SUN, Chi; QIU, Xipeng; XU, Yuanbin; HUANG, Xuanjing. **How to fine-tune BERT for text classification?** In: CHINESE COMPUTATIONAL LINGUISTICS, 18., 2019, Kunming. *Proceedings...* Cham: Springer, 2019. p. 194–206.

TRIBUNAL DE CONTAS DA UNIÃO. **Portal de Dados Abertos do TCU: Acórdãos Completos**. Brasília: TCU, 2024. Disponível em: <<https://sites.tcu.gov.br/dados-abertos/jurisprudencia/>>. Acesso em: 5 jun. 2026.

TVEITA, Sondre; HUSTAD, Eli. **Benefits and challenges of AI in the public sector**. In: HAWAII INTERNATIONAL CONFERENCE ON SYSTEM SCIENCES, 58., 2025, Maui. *Proceedings...* Honolulu: University of Hawaii, 2025. p. 1–10.

VASWANI, Ashish et al. **Attention is all you need**. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. *Proceedings...* Red Hook: Curran Associates, 2017. p. 5998–6008.

WOLF, Thomas et al. **Transformers: state-of-the-art natural language processing**. In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS, 2020, online. *Proceedings...* Stroudsburg: ACL, 2020. p. 38–45.