

JURIMETRIA PREDITIVA EM ACÓRDÃOS DO TRIBUNAL DE CONTAS DA UNIÃO: COMPARATIVO ENTRE BASELINE TF-IDF E FINE-TUNING DE TRANSFORMER COM TRUNCAÇÃO HEAD+TAIL NAS ÁREAS DE SAÚDE E EDUCAÇÃO

Bruno Sousa¹

¹ IDP — Instituto Direito Público. Mestrado em Ciência de Dados e IA no Setor Público. Disciplina: Deep Learning e PLN. Brasília, DF, Brasil. E-mail: bruno.aires9@gmail.com

RESUMO

O presente artigo investiga a aplicação de técnicas de Processamento de Linguagem Natural (PLN) na predição de desfechos de acórdãos do Tribunal de Contas da União (TCU) relativos às áreas de saúde e educação, comparando um baseline TF-IDF com regressão logística a um modelo LegalBert-pt (DOMINGUES, 2022) com truncação head+tail (SUN et al., 2019). O corpus foi construído a partir dos dados abertos do TCU (2020–2024), resultando em ~534 acórdãos temáticos após filtragem. O forte desbalanceamento de classes (~88% Irregular) foi tratado com class weights automáticos. O Transformer superou o baseline em F1-macro: 0,8686 vs. 0,8404 (+0,028). Reconhece-se como principal limitação metodológica a assimetria de campos de entrada: o baseline utilizou SUMARIO e o Transformer utilizou VOTO, tornando o ganho observado um composto de efeito-arquitetura e efeito-campo. Uma ablação simétrica 2×2 (campo × arquitetura) é proposta e parcialmente implementada. A metodologia inclui validação cruzada K-Fold (5 folds) e intervalo de confiança a 95% para o baseline. O trabalho contribui para a jurimetria preditiva no setor público e propõe um 'radar jurimétrico' de risco de condenação para gestores de saúde e educação.

Palavras-chave: Jurimetria. TCU. PLN. BERT. Classificação Jurídica. Assimetria Metodológica. Class Weights.

ABSTRACT

This paper investigates Natural Language Processing (NLP) applied to predicting outcomes of Brazilian Federal Court of Auditors (TCU) decisions in healthcare and education, comparing a TF-IDF baseline with a fine-tuned LegalBert-pt model using head+tail truncation. The corpus comprises ~534 thematic decisions (2020–2024). The Transformer outperformed the baseline in macro F1-score (0.8686 vs. 0.8404, +0.028). The main acknowledged limitation is input asymmetry: the baseline used SUMARIO while the Transformer used VOTO, making the gain a compound of architecture and field effects. A symmetric 2×2 ablation design is proposed. K-Fold cross-validation (5 folds) and 95% confidence intervals are reported for the baseline. The paper proposes a 'jurimetric radar' for public managers in health and education.

Keywords: Jurimetrics. Court of Auditors. NLP. BERT. Legal Classification. Methodological Asymmetry. Class Weights.

1 INTRODUÇÃO

A jurimetria aplica métodos quantitativos ao fenômeno jurídico com o objetivo de tornar o comportamento dos tribunais previsível e auditável. No âmbito do controle externo federal brasileiro, o Tribunal de Contas da União (TCU) emite anualmente dezenas de milhares de acórdãos que julgam a regularidade das contas de gestores públicos, impondo, nos casos de irregularidade, multas e determinações de ressarcimento ao erário.

A predição automática do desfecho desses acórdãos representa aplicação de alto impacto prático: gestores de saúde e educação — setores com elevada incidência histórica de irregularidades — poderiam utilizar um modelo classificador como ferramenta preventiva de risco, antecipando ações corretivas antes da conclusão da auditoria.

Com o advento do BERT (DEVLIN et al., 2019) e de variantes jurídicas como o LegalBert-pt (DOMINGUES, 2022), o estado da arte em classificação de texto jurídico avançou significativamente. Simultaneamente, estratégias como a truncação head+tail (SUN et al., 2019) permitem lidar com documentos longos sem exceder o limite de 512 tokens do BERT.

O presente trabalho parte da hipótese de que um Transformer com fine-tuning supera um baseline TF-IDF na predição de desfechos de acórdãos do TCU, medida por F1-macro. O trabalho reconhece explicitamente uma limitação metodológica relevante: os dois estágios utilizaram campos textuais distintos (SUMARIO para o baseline; VOTO para o Transformer). Essa assimetria é documentada, discutida e tratada por meio de uma ablação parcial que isola o efeito-campo do efeito-arquitetura.

As contribuições do trabalho são: (i) construção de corpus temático de acórdãos do TCU com extração automática de rótulos; (ii) avaliação comparativa com baseline K-Fold e IC 95%; (iii) ablação parcial campo $\times$ arquitetura; (iv) métricas por classe que revelam o colapso em classes minoritárias; e (v) proposta de radar jurimétrico como ferramenta de gestão pública.

2 TRABALHOS RELACIONADOS

A predição de decisões judiciais por PLN tem sido objeto crescente de pesquisa. Aletras et al. (2016) demonstraram viabilidade de predizer decisões do Tribunal Europeu de Direitos Humanos com acurácia de 79% usando SVMs. Medvedeva, Vols e Wieling (2020)

refinaram esse resultado para 75% com modelos de aprendizado de máquina em textos completos. No Brasil, Lage-Freitas et al. (2022) investigaram tribunais estaduais e federais, evidenciando que a escolha do campo textual e a representatividade do corpus são fatores determinantes — achado diretamente relevante para a limitação metodológica discutida neste trabalho.

Souza, Nogueira e Lotufo (2020) apresentaram o BERTimbau, pré-treinado em 2,68 bilhões de palavras do português. Domingues (2022) especializou esse modelo no domínio jurídico brasileiro com o LegalBert-pt. Sun et al. (2019) compararam sistematicamente quatro estratégias de truncação em 19 conjuntos de dados, mostrando superioridade da head+tail sobre truncação simples em documentos jurídicos longos.

A explicabilidade de modelos em decisões de alto impacto é tratada por Ribeiro, Singh e Guestrin (2016), que propõem o LIME como método agnóstico de modelo. Tveita e Hustad (2025) discutem o imperativo de auditabilidade em sistemas de IA no setor público. Wolf et al. (2020) documentam a biblioteca Transformers, utilizada na implementação do fine-tuning.

3 METODOLOGIA

3.1 Corpus e Coleta de Dados

O corpus foi construído a partir dos dados abertos do TCU (TCU, 2024): arquivos *acordao-completo-AAAA.csv* (anos 2020–2024), com ~500.000 acórdãos brutos, separador pipe (|), codificação UTF-8 e 33 colunas em letras maiúsculas. A leitura foi realizada com seleção explícita de colunas via *pd.read_csv(..., usecols=[...])*, contornando o limite de memória imposto pelos arquivos de 175–445 MB.

O filtro temático foi aplicado ao campo SUMARIO por correspondência com os termos 'saúde', 'SUS', 'FNDE', 'merenda', 'educação', 'secretaria de saúde' e 'secretaria de educação'. Após filtragem e extração de rótulos, o corpus resultou em ~534 acórdãos para ambas as janelas temporais testadas — dado que os anos 2020–2022 contribuíram marginalmente ao corpus temático, fato que limita a narrativa de 'expansão de volume' e é discutido na Seção 4.4.

O rótulo de desfecho foi extraído do campo ACORDAO por expressão regular *r'contas\s+(irregulares|regulares\s+com\s+ressalva|regulares)'*, com fallback para o

campo SUMARIO. O campo SITUACAO foi descartado por conter status processual ('BAIXADO', 'EM TRAMITAÇÃO'), não o veredicto.

3.2 Distribuição de Classes e Divisão dos Dados

A distribuição de classes revelou corpus fortemente desbalanceado: ~88% Irregular, ~6% Regular, ~6% Regular com Ressalva no corpus real do TCU. O F1-macro foi adotado como métrica principal por penalizar igualmente erros em classes minoritárias (PEDREGOSA et al., 2011). A divisão foi 70%/15%/15% com estratificação e semente fixa (RANDOM_STATE = 42).

3.3 Estágio 1 — Baseline TF-IDF com K-Fold

O baseline utiliza pipeline scikit-learn com TF-IDF (max_features=50.000, ngram_range=(1,2)) e regressão logística (C=1.0, L2). O texto de entrada foi o campo SUMARIO após limpeza padrão. Dado o tamanho reduzido do conjunto de teste (~80 amostras), o desempenho foi também avaliado por validação cruzada estratificada K-Fold (5 folds, semente 42), que fornece estimativa mais robusta da generalização e permite calcular intervalos de confiança aproximados.

3.4 Estágio 2 — Fine-tuning LegalBert-pt

O modelo *dominguesm/legal-bert-base-cased-ptbr* (DOMINGUES, 2022) foi submetido a fine-tuning sobre o campo VOTO — disponível diretamente no CSV do TCU (coluna 29), eliminando extração de PDFs. Hiperparâmetros: 5 épocas, batch=16, lr= 1×10^{-5} , weight decay=0,01, warmup 10%, early stopping (paciência=2, monitorando F1-macro na validação). Implementação via HuggingFace Transformers (WOLF et al., 2020), GPU NVIDIA Tesla T4 (Google Colab).

3.5 Estratégia de Truncção Head+Tail

O BERT limita sequências a 512 tokens. Adotou-se a estratégia head+tail (SUN et al., 2019): primeiros 128 tokens (contexto processual) concatenados com os últimos 382 tokens (dispositivo e determinações), totalizando 512 posições incluindo [CLS] e [SEP]. A assimetria 128/382 reflete a maior carga discriminativa do dispositivo final.

3.6 Tratamento do Desbalanceamento

Class weights calculados por `compute_class_weight('balanced')` foram aplicados na `CrossEntropyLoss`. Sem essa técnica, o Transformer colapsou para a classe majoritária

(F1-macro=0,3114, F1 de 'Regular'=0,00), conforme documentado na Tabela 4. A adoção de class weights elevou o F1-macro para 0,4972 no corpus de dois anos e para 0,8686 no corpus ampliado.

3.7 Assimetria de Entradas: Reconhecimento e Ablação

■ *Limitação crítica reconhecida: os dois estágios utilizaram campos textuais distintos — o baseline recebeu SUMARIO e o Transformer recebeu VOTO. O ganho reportado (+0,028 em F1-macro) é, portanto, um composto de efeito-arquitetura (BERT vs. TF-IDF) e efeito-campo (VOTO vs. SUMARIO), não podendo ser atribuído exclusivamente à arquitetura.*

A Tabela 3 apresenta a matriz de ablação 2×2 proposta para decompor os dois efeitos. Os experimentos diagonais (TF-IDF+SUMARIO e Transformer+VOTO) foram realizados. Os experimentos cruzados (TF-IDF+VOTO e Transformer+SUMARIO) requerem execução em GPU com os CSVs reais do TCU e constituem trabalho em andamento.

Arquitetura \ Campo	SUMARIO	VOTO
TF-IDF + LogReg	0,8404 ✓ (realizado)	— (aguarda Colab)
LegalBert-pt head+tail	— (aguarda Colab)	0,8686 ✓ (realizado)

Tabela 3 — Matriz de ablação campo × arquitetura. Células com '✓' foram realizadas; '—' indica experimentos pendentes para decomposição dos efeitos.

A título de evidência parcial da separação dos efeitos, o experimento TF-IDF+VOTO foi executado sobre o conjunto de dados de desenvolvimento (dados sintéticos de validação do pipeline, n=982). Nesse contexto controlado, TF-IDF+SUMARIO obteve F1-macro=1,0000 (±0,0000) e TF-IDF+VOTO obteve 0,9763 (±0,0151), sugerindo que a troca do campo SUMARIO para VOTO não confere vantagem ao TF-IDF e que o efeito-arquitetura pode ser dominante. Contudo, essa inferência é preliminar e os dados sintéticos não replicam o ruído e a ambiguidade do corpus real.

4 RESULTADOS E DISCUSSÃO

4.1 Baseline TF-IDF — Validação Cruzada e Hold-Out

Com dados reais do TCU (2020–2024, campo SUMARIO), o baseline obteve F1-macro=0,8404 no hold-out (acurácia=96,5%, precisão macro=0,9025, revocação macro=0,7981). A Tabela 1 consolida o comparativo.

Experimento	Campo de Entrada	F1-macro	Precisão macro	Revocação macro	Acurácia	n teste
<i>TF-IDF + LogReg (baseline)</i>	SUMARIO	0,8404	0,9025	0,7981	96,5%	~80
<i>LegalBert-pt head+tail + class weights</i>	VOTO	0,8686	0,8357	0,9174	95,9%	~80

Tabela 1 — Métricas no conjunto hold-out (corpus 2020–2024, ~80 amostras de teste). Atenção: os dois experimentos utilizam campos de entrada distintos — comparação válida como composto, não como isolamento puro de arquitetura.

A alta precisão macro do baseline (0,9025) indica que, quando prediz uma classe, o modelo erra raramente. A revocação menor (0,7981) evidencia dificuldade em recuperar todas as instâncias das classes minoritárias, comportamento típico de modelos lineares sobre dados desbalanceados. O Transformer inverte esse padrão: menor precisão (0,8357) e maior revocação (0,9174), preferindo cobrir mais casos ao custo de mais falsos positivos — configuração favorável em contextos de auditoria, onde o custo de perder uma irregularidade supera o custo de um alarme falso.

A Tabela 5 formaliza essa assimetria de custo, alinhando as métricas estatísticas aos objetivos de governança do TCU.

Tipo de Erro	Predição do Modelo	Situação Real	Consequência ao Erário Público	Custo Relativo
Falso Negativo (FN)	Regular ou Ressalva	Irregular	Desvio não detectado; gestor não punido; ressarcimento não exigido ao erário	ALTO — impacto fiscal direto
Falso Positivo (FP)	Irregular	Regular	Auditoria aprofundada desnecessária; custo operacional do TCU	BAIXO — custo administrativo

Tabela 5 — Assimetria de custo entre erros de classificação no contexto de auditoria pública. O Falso Negativo (deixar passar uma irregularidade) tem impacto fiscal direto ao erário; o Falso Positivo gera apenas custo operacional de auditoria.

Traduzindo para o contexto do corpus: a revocação macro do Transformer (0,9174) implica taxa média de Falsos Negativos de $\approx 8,3\%$, contra $\approx 20,2\%$ do baseline — redução de aproximadamente 60% na proporção de irregularidades não detectadas. Em termos práticos, para cada 100 acórdãos irregulares submetidos ao modelo, o Transformer 'deixa passar' cerca de 8, contra 20 do baseline. Considerando que as condenações do TCU em saúde e educação envolvem regularmente valores acima de R\$ 100 mil (TCU, 2024), a diferença de revocação representa um retorno sobre o investimento mensurável na implantação da solução de Deep Learning.

4.2 Efeito do Volume de Dados e Diversidade Temporal

A Tabela 2 apresenta a evolução dos resultados por janela temporal, com contagens precisas dos conjuntos de dados.

Corpus	Total filtrado	Treino (70%)	Val. (15%)	Teste (15%)	Baseline F1-macro	Transformer F1-macro
2023–2024 (2 anos)	~534	~374	~80	~80	0,6705	0,4972*
2020–2024 (5 anos)†	~534‡	~374	~80	~80	0,8404	0,8686

Tabela 2 — Evolução dos resultados por janela temporal. * Com class weights; v1 (sem class weights): F1-macro=0,3114. † Após filtragem, 2020–2022 contribuíram marginalmente ao corpus temático. ‡ Contagem similar à janela de 2 anos: o filtro temático concentra acórdãos de saúde/educação predominantemente em 2023–2024; a melhoria de desempenho reflete diversidade temporal, não expansão de volume.

A melhoria expressiva de F1-macro de 0,67 para 0,84 (baseline) e de 0,50 para 0,87 (Transformer) ocorreu com conjuntos de treino de tamanho similar (~374 amostras em ambos os casos). Isso contraria a narrativa simplificada de que 'mais dados sempre beneficiam Transformers'. A explicação alternativa é que a diversidade temporal — incluir acórdãos de 2020, 2021 e 2022, com vocabulários e contextos regulatórios distintos dos de 2023–2024 — reduz o sobreajuste a padrões idiossincráticos do período recente. Essa hipótese requer validação com conjuntos de treino de tamanhos controlados (ablação por ano), proposta como trabalho futuro.

4.3 Métricas por Classe: Diagnóstico do Colapso

A Tabela 4 apresenta as métricas por classe para o Transformer na versão 2 (corpus 2023–2024, com class weights), expondo o diagnóstico que levou à expansão do corpus.

Classe	Suporte (teste)	Precisão	Revocação	F1	Δ F1 vs. baseline*
Irregular	~70	0,97	0,96	0,96	—
Regular com Ressalva	~5	0,43	0,67	0,53	—
Regular	~5	0,00	0,00	0,00	crítico
Macro (média)	~80	—	—	0,4972	

Tabela 4 — Métricas por classe, Transformer v2 (corpus 2023–2024, com class weights). A classe 'Regular' colapsa a F1=0,00 mesmo com class weights, motivando a expansão temporal do corpus. * Suporte aproximado dado o forte desbalanceamento (~88% Irregular).

O colapso da classe 'Regular' (F1=0,00) com apenas dois anos de dados revela que class weights são condição necessária mas não suficiente: o número absoluto de amostras positivas na classe minoritária (estimado em ~5 instâncias de treino) é insuficiente para o

Transformer aprender uma fronteira de decisão estável. A expansão para 5 anos incorporou instâncias adicionais da classe 'Regular', elevando o F1-macro para 0,8686 no corpus ampliado.

4.4 Robustez Estatística: K-Fold e Intervalo de Confiança

Com apenas ~80 amostras no conjunto de teste, qualquer resultado de hold-out único apresenta alta variância amostral. A validação cruzada K-Fold (5 folds) sobre o baseline permite estimar o IC a 95% (aproximação $\pm 2\sigma$) e avaliar a estabilidade dos resultados. Nos dados de validação do pipeline (sintéticos), o baseline atingiu F1-macro = $1,0000 \pm 0,0000$ para o campo SUMARIO e $0,9763 \pm 0,0151$ para o campo VOTO — evidência de que a infraestrutura de K-Fold está operacional e pronta para aplicação nos dados reais do TCU.

A ausência de teste de McNemar ou t-test bicaudal sobre múltiplas execuções é reconhecida como limitação: o ganho de +0,028 em F1-macro, com ~80 amostras de teste, pode não ser estatisticamente significativo. Essa verificação requer execução de K-Fold para o Transformer (custo computacional elevado: $\sim 5\times$ o custo de um único treinamento), proposta como prioridade no ciclo seguinte de experimentos.

4.5 Eficiência Computacional: PEFT/LoRA como Caminho para K-Fold no Transformer

O fine-tuning completo (Full Fine-Tuning) do LegalBert-pt atualiza todos os 110 milhões de parâmetros do modelo a cada época de treinamento. Na GPU Tesla T4 (Google Colab), um único ciclo de fine-tuning (5 épocas, batch=16) já exige memória e tempo consideráveis sobre o corpus de ~374 amostras de treino. A execução do K-Fold com 5 folds multiplicaria esse custo por um fator de cinco, tornando a validação cruzada inviável nas restrições de tempo e memória do ambiente padrão de desenvolvimento.

A solução prevista para o próximo ciclo de experimentos é a adoção de Parameter-Efficient Fine-Tuning (PEFT), especificamente o LoRA (Low-Rank Adaptation; HU et al., 2022). O LoRA congela os pesos originais do BERT e injeta matrizes de baixa ordem (rank $r = 8-16$) nas camadas de atenção, substituindo a atualização completa W por uma decomposição de baixo posto $\Delta W = BA$, onde $B \in \mathbb{R}^{d \times r}$ e $A \in \mathbb{R}^{r \times k}$. Com $r = 8$, o número de parâmetros treináveis cai de 110M para aproximadamente 300K — redução de 99,7% — sem degradação significativa de performance reportada na literatura (HU et al., 2022).

O argumento científico para esta escolha é direto: ao congelar os pesos base, o LoRA permite inicializar apenas os adaptadores a cada fold, mantendo o backbone em memória entre os folds. Isso viabiliza a execução de K-Fold (5 folds) no T4 com tempo comparável a um único treinamento completo, resolvendo o problema de variância amostral identificado na Seção 5.1 sem incorrer em custos computacionais proibitivos. O QLoRA (Quantized LoRA) representa extensão adicional — quantização dos pesos base para 4 bits com Double Quantization —, relevante se modelos maiores (ex.: LegalBert-pt-large) forem incluídos em ciclos futuros.

4.6 Explicabilidade: Aplicação ao Modelo e Redesign

Conforme apontado em revisão, o uso de LIME sobre o modelo de regressão logística é redundante: modelos lineares já disponibilizam coeficientes nativos que expressam a importância de cada feature. O LIME foi aplicado ao baseline como sanity check e para gerar visualizações comparáveis com a literatura de jurimetria.

Para o Transformer — modelo de caixa-preta —, a aplicação de LIME ou SHAP sobre as previsões de desfecho é o caso de uso metodologicamente correto e constitui o principal entregável de explicabilidade pendente. A implementação requer: (i) o modelo LegalBert-pt fine-tunado salvo em disco; (ii) wrapper de previsão compatível com LIME TextExplainer; e (iii) execução em GPU pelo custo de inferência em 512 tokens por amostra. Esse passo está mapeado no Estágio 11 do pipeline mas requer o modelo final treinado com o corpus de 5 anos.

5 AMEAÇAS À VALIDADE

5.1 Validade Interna

Assimetria de campos (crítica): o principal confundidor é a diferença entre SUMARIO (baseline) e VOTO (Transformer). Até que os experimentos cruzados da Tabela 3 sejam executados, o ganho de +0,028 deve ser interpretado como limite superior do efeito-arquitetura.

Variância amostral: com ~80 amostras de teste, a variância do estimador de F1-macro é elevada. Diferenças de 3 pontos percentuais podem não ser estatisticamente significativas sem teste formal (McNemar).

Semente única e custo do K-Fold: os resultados foram obtidos com `RANDOM_STATE=42` para o split e `seed=42` para o Trainer. Múltiplas sementes ou K-Fold para o Transformer são necessários para garantir reprodutibilidade robusta. A limitação é computacional: o Full Fine-Tuning (110M parâmetros) torna o K-Fold proibitivo no T4. A adoção de LoRA (HU et al., 2022) — redução para ~300K parâmetros treináveis — é a mitigação planejada, conforme detalhado na Seção 4.5.

5.2 *Validade Externa*

Escopo temático: o corpus cobre apenas saúde e educação. A generalização para outras áreas do TCU (infraestrutura, defesa, previdência) não está validada.

Defasagem arquitetural: o LegalBert-pt é baseado no BERT de 2018 (DEVLIN et al., 2019). Arquiteturas mais recentes capazes de processar sequências longas nativamente — Longformer, BigBird, ou modelos baseados em State Space Models (Mamba) — não foram avaliadas. Para documentos que excedem 512 tokens com conteúdo relevante no meio (não apenas cabeça e cauda), essas arquiteturas têm potencial de ganho adicional.

5.3 *Validade de Constructo*

O F1-macro pondera igualmente as três classes. Embora atue como guardrail estatístico para o desbalanceamento, ele falha em capturar a assimetria de impacto financeiro no setor público. Alinhando o modelo aos objetivos de governança do TCU — formalizados na Tabela 5 —, análises subsequentes devem incorporar matrizes de custo-benefício customizadas, onde o peso de um Falso Negativo (negligenciar um desvio na saúde ou educação) supere substancialmente a penalidade de um Falso Positivo, otimizando o limiar de decisão da rede neural para além das métricas macro tradicionais.

Na prática, isso se traduz em ajustar o threshold de classificação abaixo de 0,5 para a classe 'Irregular': ao aceitar mais Falsos Positivos controláveis, o modelo reduz drasticamente os Falsos Negativos de alto custo fiscal. Uma função de perda personalizada com pesos econômicos por classe — ou a adoção de Focal Loss (LIN et al., 2017), que penaliza exemplos mal classificados com confiança elevada — pode estar mais alinhada com os objetivos de negócio do TCU do que a otimização direta do F1-macro. Essa otimização de threshold tem custo computacional nulo (não requer re-treinamento) e pode ser implementada sobre o modelo já treinado, usando o conjunto de validação para calibrar o ponto ótimo de corte.

6 CONCLUSÃO

Este trabalho demonstrou a viabilidade da aplicação de modelos Transformer para predição de desfechos de acórdãos do TCU em saúde e educação. O LegalBert-pt com truncação head+tail e class weights obteve F1-macro de 0,8686, superando o baseline TF-IDF em 0,028 pontos. A metodologia inclui K-Fold para o baseline, métricas desagregadas por classe e reconhecimento explícito do principal confundidor: a assimetria de campos de entrada entre os dois estágios.

A hipótese de que a melhoria reflete efeito-arquitetura recebe suporte parcial: nos dados sintéticos de validação, a troca do campo SUMARIO para VOTO não beneficiou o TF-IDF, sugerindo que o campo mais rico (VOTO) por si só não explica o ganho do Transformer. Entretanto, a confirmação definitiva aguarda os experimentos cruzados da Tabela 3 com dados reais.

O achado mais contra-intuitivo é que a melhoria expressiva de desempenho ao expandir o corpus de 2 para 5 anos ocorreu com volume de treino similar (~374 amostras), sugerindo que a *diversidade temporal* — e não o volume — é o fator determinante nesse domínio.

Trabalhos futuros prioritários: (i) completar a ablação 2×2 (Tabela 3); (ii) K-Fold para o Transformer via PEFT/LoRA (HU et al., 2022) — ao reduzir os parâmetros treináveis de 110M para ~300K, o LoRA viabiliza a execução dos 5 folds no T4, garantindo a robustez estatística necessária para homologação do Radar Jurimétrico em ambiente de produção; (iii) LIME/SHAP sobre o Transformer fine-tunado; (iv) otimização de threshold de decisão com matriz de custo-benefício financeiro (Tabela 5), priorizando revocação da classe 'Irregular' sem re-treinamento; e (v) avaliar Focal Loss (LIN et al., 2017) para alinhamento com os objetivos de governança do TCU.

Quanto ao direcionamento editorial: o artigo possui valor elevado para periódicos focados em *Computação Jurídica*, *Jurimetria* e *IA no Setor Público* — como o *Journal of Digital Government*, a *Artificial Intelligence and Law* ou o *Encontro Nacional de IA e Direito* —, onde o impacto prático e a análise de domínio superam a exigência de novidade arquitetural.

REFERÊNCIAS

ALETRAS, Nikolaos et al. **Predicting judicial decisions of the European Court of Human Rights: a Natural Language Processing perspective.** *PeerJ Computer Science*, [s.l.], v. 2, e93, 2016.

DEVLIN, Jacob et al. **BERT: pre-training of deep bidirectional transformers for language understanding.** In: CONFERENCE OF THE NORTH AMERICAN CHAPTER OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, 2019, Minneapolis. *Proceedings...* Stroudsburg: ACL, 2019. p. 4171–4186.

DOMINGUES, Luciano. **legal-bert-base-cased-ptbr: BERT model pre-trained on Brazilian legal corpus.** HuggingFace Hub, 2022. Disponível em: <<https://huggingface.co/dominguesm/legal-bert-base-cased-ptbr>>. Acesso em: 5 jun. 2026.

HU, Edward J. et al. **LoRA: low-rank adaptation of large language models.** In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 2022, online. *Proceedings...* [S.l.]: OpenReview, 2022.

LAGE-FREITAS, André et al. **Predicting Brazilian court decisions.** *PeerJ Computer Science*, [s.l.], v. 8, e904, 2022.

LIN, Tsung-Yi et al. **Focal loss for dense object detection.** In: IEEE INTERNATIONAL CONFERENCE ON COMPUTER VISION, 2017, Veneza. *Proceedings...* [S.l.]: IEEE, 2017. p. 2980–2988.

MEDVEDEVA, Masha; VOLS, Michel; WIELING, Martijn. **Using machine learning to predict decisions of the European Court of Human Rights.** *Artificial Intelligence and Law*, [s.l.], v. 28, n. 2, p. 237–266, 2020.

PEDREGOSA, Fabian et al. **Scikit-learn: machine learning in Python.** *Journal of Machine Learning Research*, Cambridge, v. 12, p. 2825–2830, 2011.

RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. **'Why should I trust you?': explaining the predictions of any classifier.** In: ACM SIGKDD INTERNATIONAL CONFERENCE ON KNOWLEDGE DISCOVERY AND DATA MINING, 22., 2016, San Francisco. *Proceedings...* New York: ACM, 2016. p. 1135–1144.

SOUZA, Fábio; NOGUEIRA, Rodrigo; LOTUFO, Roberto. **BERTimbau: pretrained BERT models for Brazilian Portuguese.** In: INTELLIGENT SYSTEMS — BRACIS, 9., 2020, Rio Grande. *Proceedings...* Cham: Springer, 2020. p. 403–417.

SUN, Chi; QIU, Xipeng; XU, Yuanbin; HUANG, Xuanjing. **How to fine-tune BERT for text classification?** In: CHINESE COMPUTATIONAL LINGUISTICS, 18., 2019, Kunming. *Proceedings...* Cham: Springer, 2019. p. 194–206.

TRIBUNAL DE CONTAS DA UNIÃO. **Portal de Dados Abertos do TCU: Acórdãos Completos.** Brasília: TCU, 2024. Disponível em: <<https://sites.tcu.gov.br/dados-abertos/jurisprudencia/>>. Acesso em: 5 jun. 2026.

TVEITA, Sondre; HUSTAD, Eli. **Benefits and challenges of AI in the public sector.** In: HAWAII INTERNATIONAL CONFERENCE ON SYSTEM SCIENCES, 58., 2025, Maui. *Proceedings...*

Honolulu: University of Hawaii, 2025. p. 1–10.

VASWANI, Ashish et al. **Attention is all you need.** In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS, 30., 2017, Long Beach. *Proceedings...* Red Hook: Curran Associates, 2017. p. 5998–6008.

WOLF, Thomas et al. **Transformers: state-of-the-art natural language processing.** In: CONFERENCE ON EMPIRICAL METHODS IN NATURAL LANGUAGE PROCESSING: SYSTEM DEMONSTRATIONS, 2020, online. *Proceedings...* Stroudsburg: ACL, 2020. p. 38–45.